

聯邦時間序列補值-異質性 MNAR 缺失之研究

Federated Clinical Time-Series Imputation under Heterogeneous MNAR

曾令城

一、摘要：

Clinical time-series data, such as vital signs, often contain missing values due to sensor failures, clinical workflows, and human factors. In real-world healthcare settings, such missingness is frequently Missing Not At Random (MNAR). At the same time, medical data are distributed across hospitals and healthcare institutions and are difficult to centralize because of privacy and regulatory constraints, making Federated Learning (FL) an important direction for clinical time-series imputation. However, most existing federated imputation studies pay limited attention to heterogeneous MNAR missingness, and current personalized federated imputation methods mainly focus on tabular data and statistical models.

In this study, we investigate Personalized Federated Time-Series Imputation under heterogeneous MNAR settings and extend the complementarity-aware aggregation (CAFE) framework to the deep time-series imputation model SAITS (Self-Attention-based Imputation for Time Series). We construct four heterogeneous MNAR scenarios, from S1 with high complementarity to S4 with no complementarity, on clinical datasets including VitalDB, MIMIC-III, and eICU, and compare different federated aggregation methods and imputation backbones.

Experimental results show that, under highly complementary missingness, federated learning effectively reduces imputation error compared with local training. When the missing rate increases to $\rho = 0.7$, the mean absolute error (MAE) is reduced by approximately 18.4% on average. In addition, complementarity-aware aggregation further improves imputation performance in most scenarios. We also find that there is no universally best imputation backbone under heterogeneous MNAR: the relative advantage of SAITS and ICE (Iterative Conditional Expectation) varies with dataset characteristics and missingness complementarity. Finally, downstream classification experiments on eICU demonstrate that better imputation quality can also lead to better clinical prediction performance.

臨床生命徵象時間序列資料（clinical time-series）常因感測器故障、醫療流程與人為因素產生缺失值，且真實醫療場景中的缺失多屬於 Missing Not At Random（MNAR）機制。另一方面，醫療資料分散於不同醫院與醫療機構，受限於隱私與法規，難以集中訓練模型，使聯邦學習（Federated Learning, FL）成為臨床時間序列補值的重要方向。然而，多數聯邦補值研究較少探討異質性 MNAR（heterogeneous MNAR）缺失問題，且現有個人化聯邦補值方法主要聚焦於表格資料與統計模型。

本研究探討異質性 MNAR 情境下之個人化聯邦時間序列補值（Personalized Federated Time-Series Imputation），並將 CAFE 提出的 complementarity-aware aggregation 擴展至深度時間序列補值模型 SAITS。研究於 VitalDB、MIMIC-III 與 eICU 等臨床資料集建立 S1（高度互補）至 S4（完全不互補）之 heterogeneous MNAR 缺失情境，比較不同聯邦聚合方法與補值模型之表現。

實驗結果顯示，在高互補性缺失情境下，聯邦學習相較於 local training 可有效降低補值誤差，當缺失率提升至 $p=0.7$ 時平均可降低約 18.4% 的 MAE。此外，Complementarity-Aware Aggregation 在多數場景中皆能進一步提升補值效果。研究亦發現 heterogeneous MNAR 下不存在單一最佳補值模型：SAITS 與 ICE 的相對優勢會隨資料集特性與缺失互補性而改變。最後，eICU 的 downstream classification 實驗顯示，較佳的補值品質亦能帶來較佳的臨床預測表現。

關鍵字：Federated Learning, Time-Series Imputation, Missing Not At Random (MNAR), Personalized Federated Learning, Clinical Time-Series

二、研究背景、動機：

（一）臨床時間序列補值

臨床生命徵象（Vital Signs）是醫療決策與病患監測的重要依據。然而，在真實醫療場景中，由於感測器故障、醫療流程與人為因素等原因，臨床時間序列資料經常存在大量缺失值（missing data），尤其在高頻率生命徵象資料中更為常見。若缺失資料處理不當，將導致分析偏差並降低後續機器學習模型的可靠性，因此發展有效的時間序列補值（time-series imputation）技術成為智慧醫療中的重要研究議題。

（二）聯邦學習於醫療資料之應用

現有時間序列補值研究多以集中式資料（centralized data）為基礎。然而，醫療資料通常分散於不同醫院與醫療機構，並受到法規、隱私與資料安全等限制，難以直接共享原始資料或集中處理。聯邦學習（Federated Learning, FL）提

供了一種可行方案，使不同 client 能在不共享原始資料的情況下共同訓練模型，以兼顧資料隱私與模型效能。

近年來，研究開始探討聯邦式補值（Federated Imputation），利用聯邦學習提升不同 client 間的補值泛化能力與穩健性。然而，目前多數研究主要聚焦於較簡單的缺失機制，例如 MCAR（Missing Completely at Random）與 MAR（Missing at Random），較少探討真實醫療場景中更常見且更複雜的 MNAR（Missing Not At Random）缺失問題。

（三）異質性 MNAR 缺失之挑戰

此外，client 間的資料異質性（heterogeneity）也是聯邦學習中的核心挑戰之一。FedAvg（McMahan et al., 2017）與 FedProx（Li et al., 2020）等經典研究皆指出，non-IID 資料可能造成模型收斂不穩、權重發散（weight divergence）以及深度模型在 non-convex optimization 下的訓練困難；若異質性處理不當，甚至可能導致模型效能大幅下降。然而，現有多數聯邦式補值研究仍以 FedAvg 作為簡單聚合方式，研究重點多聚焦於通訊效率與隱私保護，較少深入探討 heterogeneous missingness 對 federated imputation 的影響。在醫療場景中，異質性的來源相當多樣，不同醫院可能因行政流程、量測習慣、病患族群與醫療資源差異，而形成不同的資料分布。其中，缺失率與缺失機制的差異，也是造成資料異質性的重要原因之一。

為了解決 non-IID 問題，過去研究提出了多種方法。例如，FedAvg 使用 shared initialization（共通初始化）降低 client 間的訓練發散；Zhao et al.

（2018）提出 data-sharing strategy，透過少量共享資料減少 client 與 global distribution 間的差異；FedProx（Li et al., 2020）則透過 proximal term (μ) 限制 local model 偏離 global model 的程度，以提升 heterogeneous settings 下的穩定性。此外，FedProx 亦提出以梯度變異數（gradient dissimilarity）作為衡量 client 異質性的指標。

（四）個人化聯邦學習

Personalized Federated Learning（Personal FL）研究進一步指出，在醫療、金融等高度異質性的場景下，強制所有 client 共用單一 global model 並不合理。相較於單一 global model，Personal FL 更強調利用 global knowledge 作為共享表示，再依據各 client 的本地資料特性進行個人化調整，以提升 local performance（Smith et al., 2017; Fallah et al., 2020）。

（五）現有聯邦補值研究的限制

近年開始有研究將聯邦學習應用於臨床時間序列補值問題。例如，Fed-HealthImp (Vavekanand et al., 2026) 提出結合 SAITS 與聯邦學習的臨床時間序列補值框架，並於 eICU、MIMIC 及 HiRID 等 ICU 資料集驗證聯邦補值的可行性。研究結果顯示，聯邦學習相較於單一機構訓練的模型能進一步提升補值品質與下游預測效能。

然而，現有研究多以建立單一 **global model** 為主要目標，對於真實醫療場景中常見的異質性問題仍缺乏深入探討。實際上，不同醫院除了病患族群與資料分布存在差異外，其缺失率與缺失機制亦可能顯著不同。在 **heterogeneous MNAR** 情境下，強制所有 **client** 共用同一組模型參數未必能獲得最佳效果。

此外，現有方法主要透過模型參數差異或資料量差異調整聚合權重，但較少直接利用不同 **client** 間缺失模式的互補性 (**missingness complementarity**) 進行個人化聚合。因此，如何在保護資料隱私的前提下，有效利用不同醫院間的資訊互補性，仍是聯邦時間序列補值的重要研究問題。

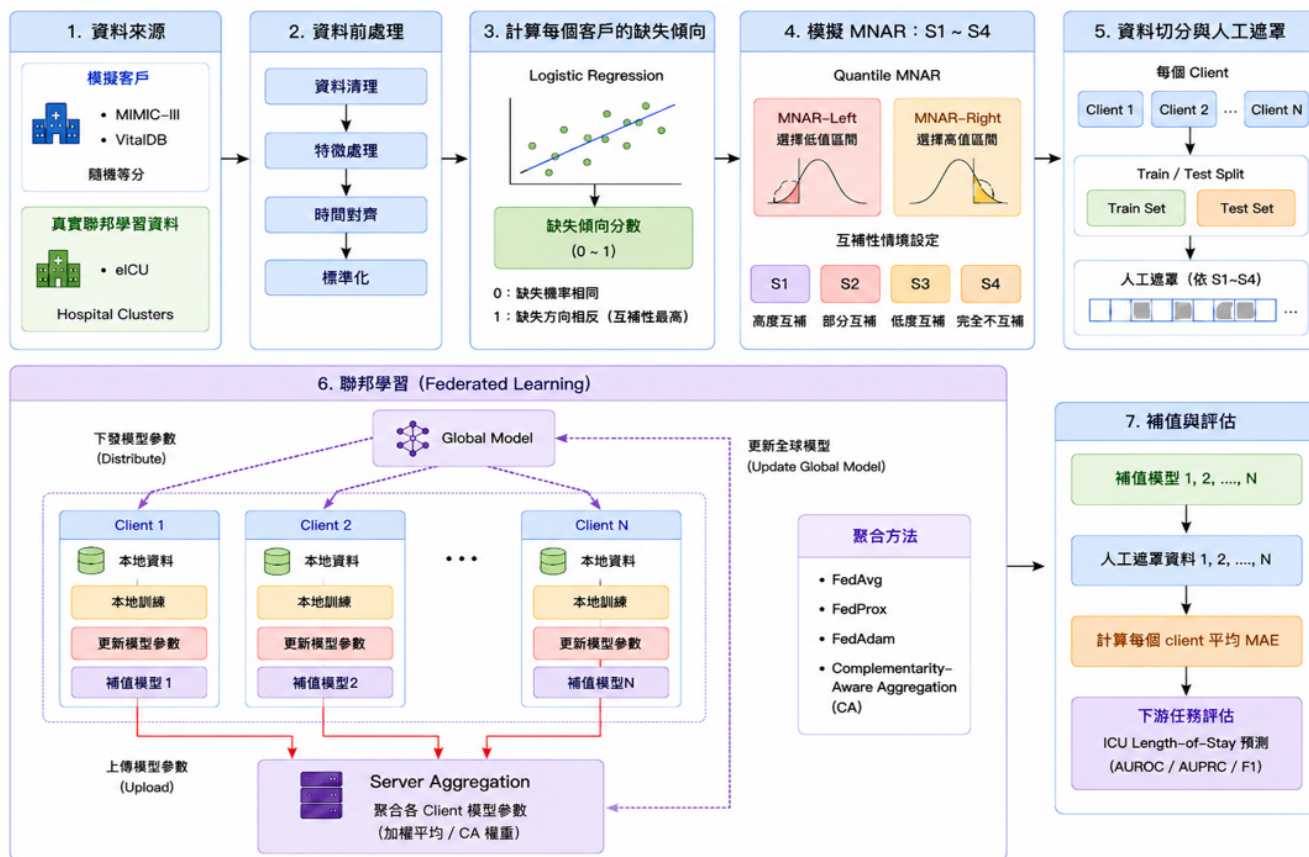
(六) CAFE 與研究缺口

為了解決 **heterogeneous MNAR** 下的個人化補值問題，Min et al. (2025) 提出 CAFE (Complementarity-Aware Federated Imputation) 進一步將 **personalized federated learning** 應用於缺失資料補值問題。CAFE 透過 **logistic regression** 建立各 **client** 的缺失傾向 (**missing tendency**)，並根據 **client** 間缺失機制的互補性 (**complementarity**) 進行個人化權重聚合，以改善 **heterogeneous MNAR** 缺失下的補值效果。然而，CAFE 主要以 **tabular data** 與統計式 ICE 模型為主，尚未探討深度時間序列補值模型在 **heterogeneous MNAR** 場景下的行為。因此，本研究旨在將 CAFE 的 **complementarity-aware aggregation** 擴展至 **clinical time-series imputation**，並系統性分析不同缺失互補性場景下，深度模型與傳統統計模型於聯邦學習中的補值表現差異。本研究以 SAITS (Self-Attention-based Imputation for Time Series) 作為深度時間序列補值模型，並與 ICE (Iterative Conditional Expectation) 進行比較。

(七) 研究目的

因此，本研究旨在探討真實醫療場景中，面對資料隱私限制、**client** 間資料異質性與 **MNAR** 缺失機制時，如何透過 **Personalized Federated Learning** 建立有效的臨床時間序列補值模型。

三、研究方法



四、圖五、系統架構圖

(一) 資料集 Datasets and Preprocessing

本研究使用三個 clinical time-series datasets 進行 federated imputation 評估：VitalDB、MIMIC-III subset，以及 eICU-demo。三個資料集分別對應不同角色：VitalDB 作為主要實驗資料集；MIMIC-III subset 與 eICU-demo 作為外部驗證，用來檢查模型行為是否只出現在單一資料集。

i. VitalDB.

VitalDB 使用已預處理 tensor，形狀為 (2500, 300, 14)，代表 2500 筆手術個案、300 個時間步、14 個 vital-sign features。原始自然缺失率約 46.3%。由於 VitalDB 並非多醫院 federated dataset，本研究將 2500 筆個案 random equal split 成 5 個 simulated clients，每個 client 約 500 筆。MNAR target features 選擇 HR、NIBP_SBP、SpO2，原因是它們分別代表 heart rate、blood pressure 與 oxygen saturation，且涵蓋較密集與較稀疏的 clinical measurements。

ii. **MIMIC-III subset.**

MIMIC-III subset 由 open_data.csv 轉換而來，tensor 形狀為 (705, 24, 4)，包含 705 筆 records、24 個時間步、4 個 features：resp_rate、heart_rate、temperature、sbp。原始自然缺失率很低，約 0.09%。因資料量較小，本研究使用 3 個 simulated clients，並將 4 個 features 全部作為 MNAR target features。本研究使用之 MIMIC-III subset 為已整理之 ICU time-series records，後續若作為正式投稿，將進一步補充 cohort selection 與 preprocessing 細節。

iii. **eICU-demo.**

eICU-demo 來自 PhysioNet eICU Collaborative Research Database Demo 2.0.1。本研究使用前 24 小時 ICU time series，以 5 分鐘為 bin，因此 sequence length 為 288。轉換後 tensor 形狀為 (1298, 288, 6)，features 包含 HR、RR、SpO2、SysBP、DiaBP、MeanBP。納入條件為 ICU stay 至少 24 小時，且 HR/RR/SpO2 在前 24 小時 coverage 至少 50%。eICU-demo 有 hospital identifiers，因此本研究使用 hospital ID 建立 5 個 balanced hospital-cluster clients，較接近真實 federated setting。

表一：

Dataset	來源	Target features	Total features	Clients	真正 federated?
VitalDB	韓國外科手術生命徵象資料	HR, NIBP_SBP, SpO2	14	5	否，random equal split 模擬
MIMIC-III subset	open_data.csv，MIMIC-style ICU time series	resp_rate, heart_rate, temperature, sbp	4	3	否，模擬 client split
eICU-demo	PhysioNet eICU Collaborative Research Database Demo	HR, RR, SpO2	6	5	是，使用 hospital-cluster clients

所有資料集皆先進行基本 physiological range filtering，超出合理範圍者視為自然缺失。為了評估人工 MNAR holes，需建立完整 reference tensor；本研究採用 forward fill 與 backward fill 補齊每筆 time series，若整個 feature 仍缺失，則以該 feature 的 observed global mean 補齊。此 reference tensor 僅用於人工 mask generation 與 metric computation，模型輸入仍只包含 observed values 與 masks。數值正規化採 per-feature z-score，mean 與 standard deviation 僅由原始 observed entries 估計。

（二）聯邦學習與互補式聚合

本研究比較兩類 imputation backbone：SAITS 與 ICE。SAITS 是 deep temporal imputation model，能建模時間序列中的 temporal dependency；ICE 則是 linear chained-equation imputation baseline，將 time series flatten 成 tabular rows 後，以 per-feature regression 進行 iterative imputation。

令第 k 個 client 的資料為：

$$X^k \in \mathbb{R}^{n_k \times T \times D}, \quad M^k \in \{0,1\}^{n_k \times T \times D}$$

其中 $M^k = 1$ 表示該位置有觀測值。模型實際輸入為：

$$O^k = X^k \odot M^k$$

SAITS 的 federated training 使用 50 communication rounds，每一 round 每個 client local train 5 epochs，batch size 為 32，learning rate 為 10^{-3} 。FedICE 則使用 20 ICE rounds，per-feature model 使用 Ridge regression。

A. FedAvg.

FedAvg 將各 client local training 後的參數依 sample size 加權平均：

$$\theta^{t+1} = \sum_{k=1}^K \frac{n_k}{\sum_j n_j} \theta_k^{t+1}$$

B. FedProx.

FedProx server-side 與 FedAvg 相同，但 local loss 加入 proximal term：

$$\mathcal{L}_k^{prox}(\theta) = \mathcal{L}_k(\theta) + \frac{\mu}{2} \|\theta - \theta^t\|_2^2$$

本研究中 $\mu = 0.01$ 。

C. FedAdam.

FedAdam 將 FedAvg update 視為 pseudo-gradient，並在 server 端使用 Adam-style momentum 更新 global model。實驗中使用 server learning rate 0.01， $\beta_1 = 0.9, \beta_2 = 0.999, \tau = 10^{-3}$ 。

D. Complementarity-aware aggregation.

CA aggregation 參考 CAFE。每個 client 先估計 missingness mechanism fingerprint。具體而言，對每個 feature d ，用 logistic regression 預測該 feature 是否缺失：

$$P(R_d^k = 1|x) = \sigma(w_d^k x + b_d^k)$$

將所有 features 的 coefficients 與 intercept 串接後得到 client fingerprint ξ^k 。兩個 clients 的互補分數定義為：

$$c_{ij} = \frac{1 - \cos(\xi^i, \xi^j)}{2}$$

其中 $c_{ij} = 0$ 代表 missing mechanism 幾乎相同， $c_{ij} = 1$ 代表方向相反、互補性最高。接著對每個 target client i ，計算其他 clients $j \neq i$ 的 personalized aggregation weight：

$$a_{ij} = (\alpha c_{ij} + (1 - \alpha) s_j)^b$$

其中 $s_j = n_j / \max_l n_l$ ， $\alpha = 0.95$ ， b 是 scale factor。正規化後：

$$w_{ij} = \frac{a_{ij}}{\sum_{\ell \neq i} a_{i\ell}}$$

最後更新 personalized model：

$\tilde{\theta}_i = \gamma \theta_i + (1 - \gamma) \sum_{j \neq i} w_{ij} \theta_j$ 其中 $\gamma = 0.02$ 。因此 CA 不是產生單一 global model，而是為每個 client 產生 personalized model。

E. Pseudo-code.

Input: client data $\{X^k, M^k\}$, backbone h , aggregation rule A

Output: imputed data $\{\hat{X}^k\}$

1. Split data into K clients.
2. Apply MNAR scenario $S1/S2/S3/S4$.
3. For each client k :
 - build observed input $O^k = X^k * M^k$
 - define evaluation mask E^k as artificial MNAR holes
4. If using CA:
 - estimate fingerprint ξ^k for each client
 - compute complementarity matrix C_{ij}
5. For each communication round:
 - each client downloads global or personalized model
 - each client trains locally
 - each client uploads updated parameters
 - server aggregates:
 - FedAvg / FedProx / FedAdam $\rightarrow$ one global model
 - CA $\rightarrow$ one personalized model per client
6. Impute missing values.
7. Evaluate MAE/RMSE only on artificial MNAR holes.

(三) MNAR 定義與模擬

Missingness 通常分為 MCAR、MAR、MNAR。MCAR 表示 missingness 與資料值無關；MAR 表示 missingness 只依賴 observed variables；MNAR 表示 missingness 依賴該變數自身未觀測到的值或 latent factors。臨床資料常具有 MNAR 特性，例如異常生命徵象可能被更頻繁量測，或某些病患因未使用特定監測設備而缺少特定 signals。本研究主要採用兩種 CAFE-inspired MNAR simulator：quantile MNAR 與 logit MNAR。Missingness taxonomy 來自 Rubin 的 MCAR/MAR/MNAR 定義；quantile/logit MNAR simulator 則參考 CAFE 論文與其實驗設定。

A. Quantile MNAR.

Quantile MNAR 定義兩種方向：

$$M(L, \rho): x_f \leq Q_f(\rho)$$

$$M(R, \rho): x_f \geq Q_f(1 - \rho)$$

其中 $Q_f(\rho)$ 是 feature 在 f observed values 上的 ρ -quantile。MNAR-Left 會遮掉低值區間，MNAR-Right 會遮掉高值區間。這種方法能明確控制缺失值落在哪一段 value range，因此非常適合用來研究 client 間 missing support 是否互補。

B. Logit MNAR.

Logit MNAR 使用 logistic model 決定 missing probability：

$$P(M_f = 0|z) = \sigma(w^\top z + b)$$

其中 z 包含 target feature 自身 value，以及與 target feature correlation 最高的一部分 features。程式會校準 intercept，使平均 missing probability 接近指定的 ρ 。Logit MNAR 的優點是比較複雜，不只是 hard threshold；但在本研究中，它比較難形成清楚的 client-level complementarity。本研究採用這兩種 MNAR 的原因是：quantile MNAR 可以明確控制 low-tail / high-tail missingness，因此適合作為主實驗；logit MNAR 則作為 robustness setting，用來測試當 missingness 比較 smooth 且難以分辨時，CA 是否仍然有效。

(一) S1 / S2 / S3 / S4 定義

本研究使用四種 heterogeneous MNAR scenarios 控制 client 間 missing support 的互補程度。


表二：

Scenario	定義	意義
S1	Client 0 使用 MNAR-Left，其餘 clients 使用 MNAR-Right	高互補性
S2	Client 0 使用 MNAR-Left，其餘 clients 使用 MNAR-Right，但 missing rate 不完全互補	部分互補性
S3	所有 clients 都使用 MNAR-Left，但 missing rate 不同	one-sided / nested missingness
S4	所有 clients 使用相同 MNAR-Left 與相同 missing rate	無互補性

S1/S2 模擬的是不同 clients 缺失 value range 不同，因此其他 clients 可能提供自己缺失區間的資訊。S3/S4 則模擬較困難的情境：所有 clients 缺失方向相同，尤其 S4 中所有 clients 都缺同一段 value range，因此 federation 不一定能提供額外資訊，甚至可能造成 negative transfer。需要注意的是，left/right 的解釋主要適用於 quantile MNAR。logit MNAR 在目前實作中沒有明確的 left/right direction，因此 logit 的 S1-S4 不應被視為嚴格復現 quantile 的互補結構，而是 complex MNAR robustness setting。

五、實驗結果


(二) **驗證聯邦學習能有效提升時間序列補值效果**：實驗結果顯示，在互補性較高的 S1 quantile MNAR 情境下，聯邦學習相較於 local training 可有效降低補值誤差；且當缺失率提高時，聯邦式補值的優勢更加明顯，在 $\rho = 0.7$ 時平均可降低約 18.4% 的 MAE。（圖一）



圖一 不同缺失率下聯邦式時間序列補值之 MAE 比較（S1 Quantile MNAR）


(三) **驗證 complementarity-aware aggregation 在時間序列補值中的有效性**
 本研究將 CAFE 的 complementarity-aware aggregation 擴展至時間序列補值，並於 eICU、MIMIC-III 與 VitalDB 進行驗證。結果顯示，FedSAITS+CA 在三個資料集的大多數 S1-S4 場景中為最低 MAE，說明缺失資料互補性可作為有效的 federated aggregation 訊號，以提升

heterogeneous MNAR 下的補值準確度。




圖二 Complementary-aware aggregation 於 heterogeneous MNAR 時間序列補值中的 MAE 比較

(四) 揭示 heterogeneous MNAR 下的模型選擇具有場景依賴性，並驗證補值品質對下游任務的影響：本研究發現，不同補值 backbone 在 heterogeneous MNAR 場景下具有不同的適用性。在 VitalDB 中，FedSAITS+CA 於高互補性場景（S1/S2）表現較佳；但在低互補性場景（S3/S4）下，FedICE+CA 反而取得較低 MAE。相對地，在 MIMIC-III 與 eICU 中，FedSAITS 在多數場景下仍維持較佳表現，尤其 eICU 的 S1-S4 皆優於 FedICE。（圖三）此外，本研究亦於 eICU 進行 ICU Length-of-Stay downstream classification 實驗。結果顯示，補值 MAE 較低的 FedSAITS+CA，在 AUROC、AUPRC 與 F1-score 等下游分類指標上亦優於 FedICE+CA，驗證較佳的 federated imputation 能提升後續臨床預測效果。（圖四）



圖三 eICU、MIMIC-III 與 VitalDB 中 S1-S4 MNAR 場景下補值 MAE



圖四 Length-of-Stay downstream classification 實驗

六、結論

本研究探討異質性 MNAR (Heterogeneous Missing Not At Random) 缺失情境下之個人化聯邦時間序列補值問題，並將 CAFE 提出的 complementarity-aware aggregation 擴展至深度時間序列補值模型 SAITS，於 VitalDB、MIMIC-III 與 eICU 等臨床資料集進行驗證。實驗結果顯示，在高互補性缺失情境下，聯邦學習相較於 local training 能有效降低補值誤差，且隨著缺失率增加，其帶來的效益更加明顯。此外，本研究驗證缺失資料互補性可作為有效的 personalized federated aggregation 訊號，FedSAITS+CA 在三個資料集的大多數場景中皆取得較佳的補值表現，顯示適當利用不同 client 間的資訊互補性有助於提升 heterogeneous MNAR 下的補值準確度。

另一方面，本研究亦發現 heterogeneous MNAR 下不存在 universally best imputation backbone。SAITS 與 ICE 的相對優勢會隨資料集特性、時間解析度與缺失互補性而改變，顯示模型選擇具有明顯的場景依賴性。此結果亦呼應 TSI-Bench (Du et al., 2025) 對時間序列補值模型的觀察，即不存在能在所有資料集與缺失情境下皆維持最佳表現的單一模型。此外，eICU 的 downstream classification 實驗顯示，較佳的補值品質亦能轉化為較佳的臨床預測表現，說明聯邦時間序列補值不僅能改善資料完整性，亦有助於提升後續醫療分析任務的效能。

綜合而言，本研究指出，在真實醫療場景中，除了資料隱私保護外，heterogeneous MNAR 所造成的資料異質性同樣是聯邦學習必須面對的重要挑戰，而 Personalized Federated Learning 與缺失互補性導向的聚合策略，可能是未來臨床時間序列補值的重要發展方向。

七、未來展望

(一) 發展更適合時間序列補值的個人化聯邦架構

本研究亦嘗試參考 FedRep (Collins et al., 2021) 之參數分離 (parameter decoupling) 概念，將 SAITS 的部分模組保留於本地端訓練，而將 attention block 進行聯邦聚合。然而實驗結果顯示，SAITS 各模組間存在高度 co-adaptation 現象，導致不同 client 的 latent representation 空間逐漸偏移，使共享 attention layer 難以有效學習跨 client 的共通時序特徵。未來可進一步探討 feature-level、time-level 或 layer-wise personalization 等更適合時間序列補值任務的個人化聯邦架構。

(二) 建立具時間感知能力的 Missingness Fingerprint

目前 complementarity-aware aggregation 所使用的 missingness fingerprint 主要透過 Logistic Regression 建立缺失傾向模型。然而，此方法缺乏對時間依賴關係的建模能力，在較複雜的 soft-logit MNAR 情境下，未必能充分反映不同 client 間的缺失互補性。未來可考慮利用 Transformer、Temporal Attention 或 Sequence Embedding 等方法建立具時間感知能力的 missingness fingerprint，以更精確地量化 client 間的缺失互補關係，進一步提升 personalized aggregation 的效果。

(三) 建立聯邦時間序列補值 Benchmark 與研究框架

目前本研究主要聚焦於 SAITS 與 ICE 兩類補值模型，以及 VitalDB、MIMIC-III 與 eICU 等臨床資料集。未來可進一步擴展至更多補值模型、更多資料集與更多 MNAR 缺失情境，建立更完整的 federated time-series imputation benchmark。此外，也可考慮與現有時間序列補值生態系統（如 PyPOTS）整合，建立可重複使用的聯邦時間序列補值研究框架，以降低研究門檻並促進後續相關研究發展。

八、附錄 Ablation Study / Appendix


(一) CA scale factor 應該設多少？

CA 的 scale factor b 控制 personalized weight 的 sharpness：

$$a_{ij} = (\alpha c_{ij} + (1 - \alpha) s_j)^b$$

CAFE 原始設定使用 $b=4$ ，但本研究發現此設定在 SAITS 上容易過度 sharp，導致 majority clients 幾乎完全被拉向某個 minority client。

在 VitalDB S1 quantile 的 scale factor sweep 中：結果顯示 $b=0.5$ 最穩定，尤其在 $\rho=0.3$ 時， $b=4$ 明顯退化。進一步 client-level analysis 顯示， $b=4$ 會讓 majority clients 將 98% 以上的 peer weight 指派給 C0。當 C0 local model 本身不夠好時，這種 hard assignment 會造成 majority degradation。因此，本研究將 FedSAITS+CA 的主要設定設為 $b=0.5$ 。FedICE+CA 則保留 CAFE-style $b=4$ ，作為與 CAFE 原始設定較一致的 baseline。



圖五：在 VitalDB S1 quantile 的 scale factor sweep

(二) Personalized FL 的 client-level 表現

CA 的重要特性是 personalized aggregation。它不是讓所有 clients 共用同一個 global model，而是依據每個 client 的 missingness fingerprint，產生不同的 personalized model。因此平均 MAE 可能掩蓋某些 clients benefit、某些 clients degrade 的現象。

在 S1 quantile 中，CA 的主要現象是 majority-to-C0 pull。當 scale factor 太大時，majority clients 會被強烈拉向 C0。以 $\rho=0.3$ 為例，C0 local MAE 約 0.816，majority local MAE 約 0.715，代表 C0 本身較弱。但 $b=4$ 讓 majority 幾乎複製 C0 model，導致 majority CA MAE 上升到約 0.900，相對 FedAvg majority 退化約 20.21%。相反地，在 $\rho=0.7$ 時，C0 雖然 local MAE 仍不一定比 majority 好，但它的 model parameter 可能帶有較強的 complementary

signal。此時 majority 經 CA 後 MAE 降至約 0.655，相對 FedAvg majority 改善約 13.98%。

這說明 CA 是否有效不能只看 complementarity score，也要看被高權重引用的 client model 是否真的包含 useful complementary information。

(三) Held-out Train/Test Validation for Imputation

主實驗採用 imputation reconstruction protocol：在原本已觀測的位置上人工產生 MNAR holes，並評估模型是否能補回這些被遮蔽的值。此設定能精準控制 missingness mechanism，並確保 evaluation ground truth 可靠。然而，這類評估可能被質疑為模型是在同一批 cases 上訓練與補值，無法排除「只是在補自己的資料」的疑慮。因此，本研究額外設計 client-local held-out validation，檢查主要結論是否能延伸到未參與訓練的 client-local test cases。

Held-out validation 的流程如下。首先，將 VitalDB 的 2500 筆 cases 分成 5 個 clients。接著，在每個 client 內部再切分 train/test cases，其中 test size 為 10%。MNAR masking 分別套用於 train cases 與 test cases；模型訓練、FedAvg aggregation、FedSAITS+CA aggregation，以及 CA fingerprint estimation 均只使用 train cases。最後，每個 client 的 final model 只在該 client 的 held-out test cases 上評估人工 MNAR holes 的 MAE/RMSE。換言之，test cases 不參與模型訓練，也不參與 CA fingerprint 估計。

表三：顯示 held-out validation 的結果，摘要如下

Setting	Local MAE	FedAvg MAE	FedSAITS+CA MAE	CA vs FedAvg
S1 logit $\rho = 0.7$	0.556 ± 0.061	0.362 ± 0.082	0.361 ± 0.076	$+0.03\% \pm 1.81\%$
S1 quantile $\rho = 0.3$	0.737 ± 0.051	0.740 ± 0.035	0.747 ± 0.032	$-1.07\% \pm 3.21\%$
S1 quantile $\rho = 0.7$	0.832 ± 0.052	0.709 ± 0.048	0.621 ± 0.067	$+12.51\% \pm 4.04\%$
S4 logit $\rho = 0.7$	0.530 ± 0.137	0.383 ± 0.166	0.397 ± 0.176	$-3.18\% \pm 3.02\%$


結果顯示，在高互補性的 S1 quantile $\rho = 0.7$ setting 中，FedSAITS+CA 在 held-out test cases 上仍明顯優於 FedAvg。FedAvg 的 MAE 為 0.709，而 FedSAITS+CA 降至 0.621，約有 12.51% 的 MAE reduction。這表示主實驗中

觀察到的 CA improvement 並非單純來自於在同一批 cases 上進行 reconstruction evaluation。

然而，此改善並非在所有 setting 下皆成立。在低 missingness-signal 的 S1 quantile $\rho = 0.3$ 中，FedSAITS+CA 與 FedAvg 表現接近，且略差於 FedAvg。在 logit MNAR 中，FedSAITS+CA 也沒有穩定優於 FedAvg：S1 logit $\rho = 0.7$ 幾乎與 FedAvg 相同，而 S4 logit $\rho = 0.7$ 則略差於 FedAvg。此結果與前述 complementarity heatmap 與 fingerprint analysis 一致：當 missingness mechanism 無法形成清楚、可偵測的 client complementarity 時，CA aggregation 不應被期待帶來穩定增益。因此，held-out validation 支持本文的條件式結論：FedSAITS+CA 的效益主要出現在可偵測且高互補的 MNAR 結構下；在弱互補、低訊號或 logit-based smooth MNAR setting 中，CA 與 FedAvg 接近，甚至可能略微退化。這也說明本研究不將 CA 描述為 universally superior aggregation method，而是將其定位為一種在 heterogeneous MNAR complementarity 明確時有效的 personalized federated aggregation mechanism。

（四）Logit vs Quantile MNAR：我們的 MNAR 模擬是否成功？

根據圖六 MNAR 成功製造出明確的 value-range shift。在 quantile S4 $\rho = 0.5$ 中，所有 clients 使用 MNAR-Left，因此 hidden holes 明顯集中在低值區間。Observed distribution 的 mean 約為 0，而 hidden holes mean 約為 -0.298，hidden q90 約等於 observed median 附近，代表高值區間幾乎沒有被 hidden。這符合 S4 的設計。在 quantile S1/S2 中，因為 C0 缺 low values，而 majority clients 缺 high values，aggregate hidden distribution 會同時包含兩側，但由於 majority clients 數量較多，整體 hidden mean 偏正，約 0.32。這也符合 S1/S2 的互補設計。相較之下，logit MNAR 的 hidden distribution shift 較弱。Logit S1/S2/S3/S4 的 hidden mean 約在 0.10–0.15 之間，scenario 間差異不明顯。這表示 logit MNAR 雖然產生 complex missingness，但沒有像 quantile MNAR 一樣形成清楚的 low-tail / high-tail missing support。因此，本文主結果採用 quantile MNAR 是合理的，因為它較能明確控制與驗證 heterogeneous complementarity。



圖六：Observed vs MNAR-hidden value distributions ($\rho = 0.5$)


(五) MNAR 缺失下 clients 是否真的互補？Heatmap 分析

圖七用 missingness fingerprint 的 cosine complementarity 計算 client-pair complementarity：

$$c_{ij} = \frac{1 - \cos(\xi^i, \xi^j)}{2}$$

Quantile MNAR 的 heatmap 與 scenario design 相當一致。在 S1 quantile 中，C0 與 C1–C4 的 complementarity 約 0.866–0.880，而 C1–C4 彼此之間 complementarity 接近 0。這形成清楚的 block structure：C0 是 MNAR-Left，其他 clients 是 MNAR-Right，因此 C0 與 majority clients 高互補，majority clients 彼此不互補。S2 的 off-diagonal mean complementarity 約 0.395，表示仍有方向互補，但沒有 S1 那麼極端。S3 的 off-diagonal mean 約 0.071，代表 one-sided nested missingness。S4 的 off-diagonal mean 約 0.0107，接近 no complementarity。這些結果支持：quantile S1/S2/S3/S4 的確成功建立出不同程度的 client complementarity。

B. CAFE-style client complementarity heatmaps ($\rho=0.5$)




圖七：Quantile, Logit MNAR heatmap for client to client

(六) 為什麼正文不使用 logit 結果？

Logit 結果表面上看起來 FedSAITS 表現非常好。S1 logit 下 FedSAITS 在 $\rho = 0.3, 0.5, 0.7$ 的 MAE 約為 0.339、0.337、0.354，明顯優於 FedICE+CA 的 0.642、0.552、0.567。S4 logit 中也有類似現象。但本研究不將 logit 作為正文主結果，原因是 logit MNAR 沒有形成足夠清楚的 heterogeneous complementarity structure。第一，observed vs hidden distribution 顯示 logit hidden holes 沒有明顯集中在某個 value range。第二，heatmap 顯示 logit S1/S2/S3 的 complementarity scores 很接近，scenario separation 不明顯。第三，fingerprint analysis 顯示即使換成 Logistic Regression fingerprint (LR), Mutual Information fingerprint (MI), Random Forest fingerprint (RF)，也無法在 logit MNAR 下穩定形成清楚的 majority-to-C0 complementarity pattern。

可能原因是 logit MNAR 是 smooth probabilistic missingness，不像 quantile MNAR 有 hard threshold，因此 logistic regression fingerprint 難以有效辨識 time-series missing tendency。即使改用 mutual information 或 random forest fingerprint，也沒有明顯改善。換句話說，logit setting 下 FedSAITS 表現好是重要 robustness observation，但它不適合支撐本文的 complementarity-aware aggregation 主論述。

因此，正文應主推 quantile MNAR 的 S1–S4 crossover；logit 結果放在 appendix，作為「在 complex but weakly separable MNAR 下，FedSAITS 仍具 robustness，但 CA complementarity 診斷較不明確」的補充分析。(圖八)



圖八：Logit MNAR 在不同 fingerprint 方法下的互補性可偵測性分析

九、參考文獻：

- [1] Tsai, W.-C., Chung, Y.-T., Tseng, L.-C., Chen, P.-F., Chen, P.-L., Yeh, C.-Y., Ting, L. P.-Y., & Chuang, K.-T. (2025). 基於深度神經網路的臨床生命徵象時間序列補值. UHIMA2025 & TLCMA2025, NSYSU.
- [2] Du, W., Côté, D., & Liu, Y. (2023). SAITS: Self-Attention-based Imputation for Time Series. *Expert Systems with Applications*, 219, 119619.
- [3] Cao, W., Wang, D., Li, J., Zhou, H., Li, L., & Li, Y. (2018). BRITS: Bidirectional Recurrent Imputation for Time Series. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [4] Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent neural networks for multivariate time series with missing values. *Scientific Reports*, 8, 6085.
- [5] Du, W., et al. (2025). TSI-Bench: Benchmarking Time Series Imputation. *ICLR 2025 Workshop / Benchmark Paper*.
- [6] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.
- [7] Little, R. J. A., & Rubin, D. B. (1986). *Statistical Analysis with Missing Data*. Wiley.

- [8] Van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
- [9] McMahan, B., Moore, E., Ramage, D., Hampson, S., & Arcas, B. A. y. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of AISTATS*.
- [10] Zhao, Y., Li, M., Lai, L., Suda, N., Civin, D., & Chandra, V. (2018). Federated learning with non-IID data. *arXiv preprint arXiv:1806.00582*.
- [11] Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems (MLSys)*.
- [12] Yang, Q., Liu, Y., Chen, T., & Tong, Y. (2019). Federated machine learning: Concept and applications. *ACM Transactions on Intelligent Systems and Technology*, 10(2), 1–19.
- [13] Smith, V., Chiang, C.-K., Sanjabi, M., & Talwalkar, A. (2017). Federated multi-task learning. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [14] Fallah, A., Mokhtari, A., & Ozdaglar, A. (2020). Personalized federated learning: A meta-learning approach. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [15] Li, T., Hu, S., Beirami, A., & Smith, V. (2021). Ditto: Fair and robust federated learning through personalization. *International Conference on Machine Learning (ICML)*.
- [16] Min, S., Wang, X., Asif, H., & Vaidya, J. (2025). Cafe: Improved federated data imputation by leveraging missing data heterogeneity. *IEEE Transactions on Knowledge and Data Engineering*.
- [17] Johnson, A. E. W., Pollard, T. J., Shen, L., Lehman, L.-W. H., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Celi, L. A., & Mark, R. G. (2016). MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3, 160035.

- [18] Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., & Badawi, O. (2018). The eICU Collaborative Research Database, a freely available multi-center database for critical care research. *Scientific Data*, 5, 180178.
- [19] Lee, H.-C., & Jung, C.-W. (2018). VitalDB: A high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 5, 180077.
- [20] Collins, L., Hassani, H., Mokhtari, A., & Shakkottai, S. (2021). Exploiting Shared Representations for Personalized Federated Learning. *International Conference on Machine Learning (ICML)*.